

LATIC – Ein linguistisches Analysetool für Text- und Itemcharakteristika
Dokumentation (Version 1.5.0)

Nadine Cruz Neri¹ & Florian Klückmann²

¹ Fakultät der Erziehungswissenschaft, Arbeitsbereich Pädagogische Psychologie, Universität
Hamburg

² Freiberuflicher Softwareentwickler

Hamburg, 05. September 2025

Autor:innennotiz

Bei Fragen oder Anmerkungen zur Dokumentation sowie zur Software LATIC wenden Sie sich per Mail an uns (hello@latic.software) oder hinterlassen Sie einen Kommentar in GitHub unter <https://github.com/florianklueckmann/LATIC/issues>.

Empfohlene Zitation: Cruz Neri, N., & Klückmann, F. (2025). *LATIC – Ein linguistisches Analysetool für Text- und Itemcharakteristika* (Version 1.5.0) [Computer Software]. <https://github.com/florianklueckmann/LATIC>

Inhaltsverzeichnis

1 Einleitung	4
2 Technische Details	4
3 Sprachen	4
4 Anleitung.....	4
4.1 Herunterladen und Starten der Anwendung	4
4.2 Anwendung.....	5
4.3 Allgemeine Hinweise	6
5 Funktionen von LATIC	7
5.1 Analyse auf Wortebene	7
5.1.1 Adjektive.....	7
5.1.2 Adpositionen.....	7
5.1.3 Adverbien.....	7
5.1.4 Determinanten.....	7
5.1.5 Eigennamen.....	8
5.1.6 Hilfsverben.....	9
5.1.7 Interjektionen	9
5.1.8 Konjunktionen.....	9
5.1.9 Nomen.....	9
5.1.10 Partikel	9
5.1.11 Pronomen	10
5.1.12 Satzzeichen	10
5.1.13 Symbole	10
5.1.14 Unbekannt oder Ungewiss	10
5.1.15 Verben.....	10
5.1.16 Wortlänge.....	10
5.1.17 Zahlwörter.....	11
5.2 Analyse auf Satzebene.....	11
5.2.1 Nominalphrasen	11
5.2.2 Passivkonstruktionen	11
5.2.3 Satzanzahl	12
5.2.4 Satzlänge	12

5.3 Analyse auf Textebene	13
5.3.1 Annotierter Text / annotiertes Item.....	13
5.3.2 Konnektoren.....	13
5.3.3 Lesbarkeitsindices.....	13
5.3.4 Lexikvarianz	15
5.3.5 Root Type-Token Ratio	16
5.3.6 Silbenanzahl.....	16
5.3.7 Wortanzahl.....	16
5.3.8 Worthäufigkeitsklasse.....	16
5.3.9 Zeichenanzahl mit und ohne Leerzeichen.....	16
6 Evaluation.....	17
6.1 Evaluation des Annotierens	17
6.2 Evaluation der Silbenausählung.....	18
6.3 Evaluation der Ausählung von Konnektoren.....	18
7 Literatur.....	20

LATIC – Ein linguistisches Analysetool für Text- und Itemcharakteristika

Die Rolle linguistischer Text- und Itemcharakteristika für das Textverstehen und die Leistung von Lernenden gewinnt zunehmend an Aufmerksamkeit in der Forschung. Dies geschieht in verschiedenen Bereichen wie der Mathematik (Shaftel et al., 2006), den Naturwissenschaften (Cruz Neri et al., 2021) und dem Lesen im Allgemeinen (Heppt et al., 2015). Das Ziel ist es zu untersuchen, welche linguistischen Charakteristika das Verstehen eines Textes oder eines Items erleichtern oder hemmen können (White, 2012). Zu diesem Zweck ist es unerlässlich, Texte und Items hinsichtlich verschiedener linguistischer Charakteristika zu analysieren.

LATIC ermöglicht die Analyse und Auszählung verschiedener linguistischer Charakteristika im Deutschen, Englischen, Französischen und Spanischen. Das Akronym LATIC steht dabei für „Linguistisches Analysetool für Text- und Itemcharakteristika“. Zur Annotation linguistischer Charakteristika wird das Natural Language Processing Tool namens Stanford CoreNLP (Manning et al., 2014), zurzeit in Version 4.5.10, verwendet.

2 Technische Details

LATIC ist eine Java-Anwendung, die unter der Verwendung des Stanford CoreNLP (Manning et al., 2014) die Analyse und das Auszählen von linguistischen Text- und Itemcharakteristika ermöglicht. Das Stanford CoreNLP (Manning et al., 2014) nutzt das sog. Natural Language Processing (siehe Chowdhury, 2005), um das Annotieren von Wörtern und Symbolen zu ermöglichen. Es orientiert sich dabei am Universal Dependencies Project (2014–2020). LATIC berechnet und zählt zusätzlich weitere Text- und Itemcharakteristika aus. Darunter fallen u. a. die Wortanzahl, die Anzahl von Sätzen sowie die Wortlänge.

Die Geschwindigkeit der Analyse von Items in LATIC ist abhängig von (1) der Länge des eingefügten Textes bzw. Items, (2) der ausgewählten Charakteristika sowie (3) der Leistungsfähigkeit des Computers. Die Analyse nimmt i. d. R. wenige Sekunden in Anspruch.

LATIC kann unter Windows, Linux und macOS verwendet werden. Zur Nutzung von LATIC empfehlen wir einen Arbeitsspeicher von mindestens 8 GB.

3 Sprachen

LATIC ermöglicht unter der Verwendung des Stanford CoreNLP (Manning et al., 2014) die Analyse und das Auszählen linguistischer Text- und Itemcharakteristika im Deutschen, Englischen, Französischen und Spanischen.

4 Anleitung

4.1 Herunterladen und Starten der Anwendung

Um LATIC anzuwenden, müssen Sie LATIC zunächst herunterladen. Öffnen Sie die Website <https://download.latic.software>. Über diesen Link werden Sie direkt zu der

aktuellsten Version von LATIC auf der Plattform GitHub weitergeleitet. Unter dem Reiter „Assets“, können Sie den .zip Ordner für Ihr Betriebssystem herunterladen. Im Falle, dass Sie Windows nutzen, laden Sie den Ordner „LATIC_Windows.zip“ herunter. Im Falle, dass Sie Ubuntu oder Debian (Linux) nutzen, laden Sie den Ordner „LATIC_Ubuntu_Debian.zip“ herunter. Im Falle, dass Sie (1) macOS nutzen, (2) andere Linux Betriebssysteme als die oben genannten nutzen oder (3) LATIC über die Konsole bzw. das Terminal starten möchten, laden Sie den Ordner „LATIC_jar.zip“ herunter.


Klicken Sie mit einem Rechtsklick auf den .zip Ordner und entpacken Sie ihn. Öffnen Sie nun den Ordner. In dem Ordner finden Sie weitere Instruktionen wie Sie LATIC (installieren und) starten können.

4.2 Anwendung

Wenn Sie LATIC öffnen, sehen Sie die Bedienoberfläche (Abbildung 1).

Abbildung 1

Bedienoberfläche von LATIC



Um einen Text bzw. ein Item zu analysieren, führen Sie folgende Schritte durch:

1. Stellen Sie zunächst oben rechts die Sprache des Textes bzw. des Items ein, das Sie analysieren möchten.
2. Geben Sie nun den zu analysierenden Text bzw. das zu analysierende Item in das obere Textfeld ein. Alternativ können Sie unter „Datei“ (mehrere) Dokumente

auswählen, die analysiert werden sollen. Es sind Dateien im folgenden Format zulässig: .docx, .pdf, .txt.

3. Wählen Sie rechts in der Spalte die Charakteristika aus, die analysiert werden sollen. Sie können hier zwischen verschiedenen Charakteristika der Wort-, Satz- und Textebene wählen.
4. Klicken Sie anschließend auf den Knopf „Analysieren“.
5. Die Ergebnisse der Analyse werden nun ausgegeben.
6. Um die Ergebnistabelle zu speichern, klicken Sie auf „Datei speichern“.
7. Um die Ergebnistabelle zu löschen, klicken Sie auf „Löschen“. Es erscheint ein Pop-up Fenster, das Sie bittet Ihre Entscheidung, das Ergebnis zu löschen, zu bestätigen.
8. Sollten Sie Hilfe benötigen, finden Sie unter dem Reiter „Hilfe“ mögliche Hilfestellungen.

4.3 Allgemeine Hinweise

Um zuverlässige Ergebnisse zu erhalten, ist es unerlässlich einige Faktoren zu berücksichtigen. Erstens sollten Sie auf eine korrekte Rechtschreibung (inkl. Groß- und Kleinschreibung) achten. Ansonsten ergeben sich überdurchschnittlich häufig Fehler in den Analysen.

Zweitens empfehlen wir auf Abkürzungen zu verzichten. So erhalten Sie zuverlässige Ergebnisse in Bezug auf bestimmte Charakteristika wie bspw. der durchschnittlichen Wort- und Satzlänge.

Drittens wird jede Zeichenkette als eine Einheit annotiert. Das bedeutet auch, dass Eigennamen, die aus mehreren Wörtern bestehen, mehrfach annotiert und gezählt werden. In dem Satz „Das *Rote Meer* hat einen hohen Salzgehalt.“ erhalten beide Wortteile des Roten Meeres jeweils das Tag PROP (Eigenname). Entsprechend zählt LATIC in diesem Satz zwei Eigennamen.

Viertens ist es LATIC (noch) nicht möglich, gendergerechte Sprache zu erkennen, die anhand von Satzzeichen getätigt wird (z. B. „Die *Schüler:innen* lernen.“, „Die *Lehrer/-innen* unterrichten.“). Wir empfehlen daher auf genderneutrale Sprache auszuweichen (z. B. „Die *Lehrkräfte* unterrichten.“). Im Falle, dass dies nicht möglich ist, empfehlen wir (1) die Satzzeichen für die Analyse ersatzlos zu streichen oder (2) die Paarform (z. B. „Die *Schülerinnen und Schüler* lernen.“) zu wählen, um zuverlässige Ergebnisse zu erhalten.

Fünftens muss zwischen einem Zahlwort und einer Maßeinheit ein Leerzeichen gesetzt werden (z. B. „Der Äquator ist mehr als *40.000 km* lang.“). Auf diese Weise werden sowohl die Zahlwörter als auch die Maßeinheiten als eigenständige Einheiten erkannt und erhalten

jeweils ein eigenes Tag. Maßeinheiten mit Potenzzahlen (z. B. „Die Fläche ist 20 m² groß.“) werden i. d. R. nicht als eine Maßeinheit erkannt und sollten ausgeschrieben werden, um korrekt annotiert zu werden.

5 Funktionen von LATIC

Diese Funktionen gelten nur für die deutsche Sprache. Diese decken sich weitestgehend mit den Funktionen für die französische und spanische Sprache. Für die Funktionen in der englischen Sprache, schauen Sie bitte in die englische Dokumentation von LATIC.

5.1 Analyse auf Wortebene

Jede Zeichenkette erhält ein eigenes Tag. Das Annotieren basiert auf dem Stuttgart-Tübingen-TagSet (Schiller et al., 1999). LATIC ermöglicht die Zählung der verschiedenen Wortarten. Eine Übersicht aller Tags, die mithilfe des Stanford CoreNLP (Manning et al., 2014) von LATIC ausgegeben werden, finden Sie in Tabelle 1.

5.1.1 Adjektive

Adjektive, auch Eigenschafts- oder Beiwörter genannt, sind Wörter, die ein Nomen modifizieren, indem sie dem Nomen bestimmte Eigenschaften oder Merkmale zuschreiben (Bibliographisches Institut, 2020). Bei der Annotation von Adjektiven ist zu beachten, dass ordinale Zahlen (z. B. „Das *dritte* Haus gehört meinem Onkel.“) ebenfalls als Adjektive gelistet werden. Adjektive erhalten das Tag ADJ (z. B. „Die Lampe leuchtet *hell*.“).

5.1.2 Adpositionen

Adpositionen gelten in der Linguistik als Überbegriff für Prä- und Postpositionen (Kurvon & Adler, 2008). Postpositionen bezeichnen dabei im Gegensatz zu Präpositionen Adpositionen, die hinter einem Wort stehen (z. B. „Meiner Meinung *nach* ist die Aussage richtig.“). Adpositionen erhalten das Tag ADP (z. B. „Die Kinder fahren *nach* Hause.“).

5.1.3 Adverbien

Adverbien beziehen sich auf Verben, Adjektive oder andere Adverbien. Sie definieren zusätzliche Angaben zu einem Ort (Lokaladverbien), einer Zeit (Temporaladverbien), einem Grund (Kausaladverbien) oder zu einer Art und Weise (Modaladverbien) (Eisenberg, 2013). Adverbien erhalten das Tag ADV (z. B. „Ich tanze *gerne*.“).

5.1.4 Determinanten

Determinanten ersetzen Nominalgruppen oder bilden Teile dieser Nominalgruppen. Subklassen von Determinanten sind definierte Artikel, demonstrative, possessive, indefinite und interrogative Determinanten (Engel, 1979). Im Universal Dependencies Project (2014–2020) wird darauf hingewiesen, dass die Trennung von Determinanten und Pronomen (siehe

Tabelle 1*Übersicht aller Tags*

Tag	Beschreibung	Beispiel
ADJ	Adjektive	Viele Menschen finden die Weihnachtszeit <i>besinnlich</i> .
ADP	Adpositionen	<i>Auf</i> dem Bahnhof sieht man einige Touristen.
ADV	Adverbien	<i>Hier</i> können wir unser Zelt aufbauen.
AUX	Hilfsverben	Gestern <i>ist</i> eine Band im Stadtpark aufgetreten.
CCONJ	Koordinierende Konjunktionen	Zum Frühstück gibt es Brot <i>und</i> Marmelade.
DET	Determinanten	Kinder sind in <i>der</i> Auswahl von Kleidung wählerisch.
INTJ	Interjektionen	<i>Oje</i> , das tat bestimmt ganz schön weh!
NOUN	Nomen	Manchmal schneit es im <i>Winter</i> .
NUM	Zahlwörter	Das Grundgesetz für die Bundesrepublik Deutschland wurde <i>1949</i> erlassen.
PART	Partikel	Sie weiß <i>nicht</i> , ob sie es pünktlich zum Termin schafft.
PRON	Pronomen	<i>Er</i> fand den Vortrag sehr spannend.
PROPN	Eigennamen	<i>Deutschland</i> besteht aus 16 Bundesländern.
PUNCT	Satzzeichen	Gehört das Haus, das auf der anderen Straßenseite steht, deinen Großeltern?
SCONJ	Subordinierende Konjunktionen	<i>Obwohl</i> ich schlecht geschlafen habe, bin ich nicht müde.
SYM	Symbole	= + / \ ~ # > ^
VERB	Verben	Er <i>hat</i> seinen Arzttermin völlig <i>vergessen</i> .
X	Unbekannt / ungewiss	

Abschnitt 5.1.11) nicht immer eindeutig ist. Determinanten erhalten das Tag DET (z. B. „Das Gebäude ist im viktorianischen Stil gebaut.“).

5.1.5 Eigennamen

Eigennamen sind Namen von Dingen oder Individuen und gehören zur Wortart der Nomen (Eisenberg, 2013). Bekannte Akronyme von Eigennamen sollten ebenfalls als Eigennamen erkannt werden. Eigennamen erhalten das Tag PROP (z. B. „Die *UNO* ist ein Zusammenschluss aus 193 Staaten.“).

5.1.6 Hilfsverben

Hilfsverben sind Funktionswörter, die gemeinsam mit einem Verb zusammengesetzt werden, um bestimmte grammatische Merkmale auszudrücken (Hentschel & Weydt, 1990). Hilfsverben erhalten das Tag AUX (z. B. „Sie *sollte* ihn anrufen.“).

5.1.7 Interjektionen

Interjektionen sind Wörter, die wortähnliche Lautäußerungen darstellen. Mit ihnen sollen Gefühle, Aufforderungen oder bestimmte Laute zum Ausdruck gebracht werden (Bibliographisches Institut, 2020). LATIC annotiert nur primäre Interjektionen (z. B. „*Oh* nein!“). Sekundäre Interjektionen werden nicht als solche erkannt (z. B. „*Donnerwetter!*“), sondern entsprechend ihrer ursprünglichen Wortart annotiert. Interjektionen erhalten das Tag INTJ (z. B. „*Wow*, du siehst toll aus!“).

5.1.8 Konjunktionen

Konjunktionen sind Wörter, die Satzgefüge miteinander verbinden (Bibliographisches Institut, 2020). Es kann zwischen koordinierenden sowie subordinierenden Konjunktionen unterschieden werden (Eisenberg, 2013).

5.1.8.1 Koordinierende Konjunktionen. Koordinierende Konjunktionen verbinden Sätze gleicher Form; bspw. einen Hauptsatz mit einem Hauptsatz oder einen Nebensatz mit einem Nebensatz. Koordinierende Konjunktionen werden synonym auch als nebenordnende und beiordnende Konjunktionen bezeichnet. Sie erhalten das Tag CCONJ (z. B. „Die Bäckerin kaufte Mehl *und* Zucker ein.“).

5.1.8.2 Subordinierende Konjunktionen. Subordinierende Konjunktionen leiten Nebensätze ein. Alternativ werden subordinierende Konjunktionen auch gehäuft als unterordnende Konjunktionen bezeichnet. Sie erhalten das Tag SCONJ (z. B. „Das Kind weinte, *weil* es so sehr lachte.“).

5.1.9 Nomen

Nomen, auch Hauptwörter oder Substantive genannt, bezeichnen Gattungen, Stoffe sowie Kollektiva mit spezifischen Eigenschaften (Eisenberg, 2013). Eigennamen werden gesondert annotiert (siehe Abschnitt 5.1.5). Nomen erhalten das Tag NOUN (z. B. „*Sauerstoff* ist ein chemisches *Element*.“).

5.1.10 Partikel

Partikel sind Funktionswörter, die nicht flektierbar sind und nicht den Wortarten der Präpositionen, Adverbien oder Konjunktionen zugeordnet werden können (Eisenberg, 2013). Sogenannte verbale Partikel (z. B. „to give *up*“), wie sie in der englischen Sprache genannt werden, werden im Deutschen als Adpositionen (z. B. „Ich gebe *nach*.“) bzw. Adverbien

annotiert (z. B. „Ich kaufe *ein*.“). Partikel erhalten das Tag PART (z. B. „Ich hoffe, meinen Vortrag gut *zu* meistern.“).

5.1.11 Pronomen

Pronomen ersetzen Nomen oder Nominalphrasen (Eisenberg, 2013). Im Deutschen ist es dem Stanford CoreNLP (Manning et al., 2014) nicht möglich, unterschiedliche Arten von Pronomen zu unterscheiden. Daher wird in LATIC nur die Anzahl aller Pronomen ausgegeben. Sie erhalten das Tag PRON (z. B. „*Wir* essen nur Gemüse, *welches* biologisch angebaut wurde.“).

5.1.12 Satzzeichen

Satzzeichen verdeutlichen die syntaktische Struktur eines Textes (Universal Dependencies Project, 2014–2020). Sie erhalten das Tag PUNCT (z. B. „Das Haus brennt! Ruft die Feuerwehr!“).

5.1.13 Symbole

Symbole unterscheiden sich von Worten hinsichtlich ihrer Form und/ oder ihrer Funktion (Universal Dependencies Project, 2014–2020). Sie erhalten das Tag SYM (z. B. „Die Anwältin verweist ihren Kollegen auf § 2.“).

5.1.14 Unbekannt oder Ungewiss

Wortarten oder Zeichenketten, die LATIC mithilfe des Stanford CoreNLP (Manning et al., 2014) keinem Tag zuordnen kann, werden als unbekannt bzw. ungewiss annotiert. Diese Wörter oder Zeichenketten erhalten das Tag X.

5.1.15 Verben

Ein Verb gibt ein Geschehen, eine Tätigkeit oder einen Vorgang wieder (Bibliographisches Institut, 2020). Im Rahmen des Stanford CoreNLP (Manning et al., 2014), werden Hilfsverben gesondert annotiert (siehe Abschnitt 5.1.6). Partizipien werden je nach Kontext als Verben (z. B. „Ich habe *gegessen*.“) oder als Adjektive (z. B. „Das Gerät ist zum Gebrauch *geeignet*.“) annotiert. Nominalisierte Verben (z. B. „Das *Laufen* macht Spaß.“) sollten als Nomen annotiert werden. Verben erhalten das Tag VERB (z. B. „Die Katze *schläft* auf dem Bett.“).

5.1.16 Wortlänge

Die durchschnittliche Wortlänge wird berechnet, indem die (1) Zeichenanzahl (ausgenommen von Satz- und Leerzeichen) oder (2) die Silbenanzahl durch die Wortanzahl dividiert wird. Tabelle 2 beinhaltet zwei Beispiele zur Veranschaulichung.

Tabelle 2*Beispiele zur Analyse der durchschnittlichen Wortlänge*

Beispiele	Durchschnittliche Wortlänge
<u>Katzen</u> <u>haben</u> <u>vier</u> <u>Beine</u> .	1,75 Silben
6 Zeichen 5 Zeichen 4 Zeichen 5 Zeichen	5,0 Zeichen
2 Silben 2 Silben 1 Silbe 2 Silben	
<u>Mit</u> <u>Speck</u> <u>fängt</u> <u>man</u> <u>Mäuse</u> .	1,20 Silben
3 Zeichen 5 Zeichen 5 Zeichen 3 Zeichen 5 Zeichen	4,20 Zeichen
1 Silbe 1 Silbe 1 Silbe 1 Silbe 2 Silben	

5.1.17 Zahlwörter

Zahlwörter fungieren laut dem Universal Dependencies Project (2014–2020) meistens als Determinanten, Adjektive oder Pronomen. Dabei werden Zahlwörter als Zahlen und als Wörter definiert, die eine Beziehung zu Zahlen herstellen. Um zuverlässige Ergebnisse zu erhalten, sollten die Zahlen in der arabischen Form geschrieben werden. Römische sowie ausgeschriebene Zahlen werden nicht immer korrekt vom Stanford CoreNLP (Manning et al., 2014) als Zahlwörter erkannt. Non-kardinale Zahlwörter (z. B. „erstens“, „doppelt“) werden als Adjektive oder Adverbien annotiert. Zahlwörter (inkl. Dezimalzahlen) erhalten das Tag NUM (z. B. „Ein Schaltjahr hat 366 Tage.“).

5.2 Analyse auf Satzebene**5.2.1 Nominalphrasen**

Nominalphrasen sind Wortgruppen, deren Kern ein Pronomen oder Nomen ist (Haider, 1991). LATIC zählt dabei die Phrasen, die das Stanford CoreNLP (Manning et al., 2014) als Nominalphrase annotiert (z. B. „*Der braune Bär macht seinen Winterschlaf.*“). Zusätzlich werden Präpositionalphrasen, die ein Pronomen bzw. Nomen enthalten, ebenfalls als Nominalphrasen ausgezählt (z. B. „*Blumen blühen in großen Gärten.*“). Nicht gezählt werden Nominalphrasen, die bereits als Teil einer gezählten größeren Struktur erfasst wurden. So wird bspw. im folgenden Satz nur eine Nominalphrase gezählt: „*Das Haus, das auf der gegenüberliegenden Straßenseite steht, ist grün.*“.

5.2.2 Passivkonstruktionen

Passivkonstruktionen werden verwendet, um Handelnde in den Hintergrund zu stellen und stattdessen eine durchgeführte Handlung in den Fokus zu rücken (Pafal, 2011). Die Passivkonstruktionen werden vom Stanford CoreNLP (Manning et al., 2014) markiert und von LATIC ausgezählt. Dabei werden nur reine Passivkonstruktionen ausgezählt, bei denen das Stanford CoreNLP (Manning et al., 2014) ein Hilfsverb (z. B. „wird“) sowie ein passives

nominales Subjekt identifiziert. Unreine Passivkonstruktionen, wie bspw. Das Zustandspassiv oder das modale Passiv (siehe Pafal, 2011), werden nicht ausgezählt.

5.2.3 Satzanzahl

Zeichenketten sind Sätze, wenn sie durch die folgenden Satzzeichen beendet werden: Punkte (.), Fragezeichen (?) sowie Ausrufezeichen (!). Zeilenumbrüche, Doppelpunkte (:) sowie Semikola (;) beenden keine Sätze. Wenn Sätze mit Doppelpunkten oder Semikola als eigenständige Sätze gezählt werden sollen, empfehlen wir, diese durch Punkte zu ersetzen. Tabelle 3 beinhaltet zwei Beispiele zur Veranschaulichung.

Tabelle 3

Beispiele zur Analyse der Satzanzahl

Beispiele	Satzanzahl
LATIC ist ein Analysetool. Es steht für “Linguistisches Analysetool für Text- und Itemcharakteristika”.	2
LATIC ist ein Analysetool: Es steht für “Linguistisches Analysetool für Text- und Itemcharakteristika”.	1

5.2.4 Satzlänge

Die durchschnittliche Satzlänge kann jeweils anhand (1) der Zeichenanzahl inkl. Leerzeichen, (2) der Zeichenanzahl ohne Leerzeichen, (3) der Silbenanzahl sowie (4) der Wortanzahl (inkl. Symbole und Zahlen) ausgegeben werden. Dabei wird die Zeichen- bzw. Wortanzahl jeweils durch die Satzanzahl dividiert. Leer- sowie Satzzeichen werden bei der Berechnung der Satzlänge nicht berücksichtigt. Tabelle 4 beinhaltet Beispiele zur Veranschaulichung.

Tabelle 4

Beispiele zur Analyse der durchschnittlichen Satzlänge

Beispiele	Durchschnittliche Satzlänge
<u>Morgen</u> <u>findet</u> <u>im</u> <u>Hörsaal</u> <u>eine</u> <u>Klausur</u>	12,0 Silben
6 Zeichen 6 Zeichen 2 Zeichen 7 Zeichen 4 Zeichen 7 Zeichen	44,0 Zeichen (mit Leerzeichen)
2 Silben 2 Silben 1 Silbe 2 Silben 2 Silben 2 Silben	38,0 Zeichen (ohne Leerzeichen)
<u>statt.</u>	7,0 Wörter
5 Zeichen	
1 Silbe	

Beispiele	Durchschnittliche Satzlänge
<u>Mein</u> <u>Freund</u> <u>hat</u> <u>eine</u> <u>Hündin</u> . <u>Ihr</u>	6,5 Silben
4 Zeichen 6 Zeichen 3 Zeichen 4 Zeichen 6 Zeichen 3 Zeichen	23,5 Zeichen (mit Leerzeichen)
1 Silbe 1 Silbe 1 Silbe 2 Silben 2 Silben 1 Silbe	20,0 Zeichen (ohne Leerzeichen)
<u>Name</u> <u>ist</u> <u>Bella</u> .	4,5 Wörter
4 Zeichen 3 Zeichen 5 Zeichen	
2 Silben 1 Silbe 2 Silben	

5.3 Analyse auf Textebene

5.3.1 Annotierter Text / annotiertes Item

Mit der Funktion des annotierten Textes bzw. Items gibt LATIC die Tags aus, die jeder einzelnen Zeichenkette vergeben wird. Leerzeichen erhalten dabei kein eigenes Tag. Abbildung 2 beinhaltet ein Beispiel zur Veranschaulichung.

Abbildung 2

Beispiel eines annotierten Textes bzw. Items

<u>Säugetiere</u> <u>gehören</u> <u>zur</u> <u>Klasse</u> <u>der</u> <u>Wirbeltiere</u> <u>und</u> <u>zeichnen</u> <u>sich</u> <u>durch</u> <u>bestimmte</u>											
NOUN	VERB	ADV	NOUN	DET	NOUN	CCONJ	VERB	PRON	ADP	ADJ	
<u>Charakteristika</u> <u>aus</u> <u>.</u> <u>Dazu</u> <u>gehört</u> <u>zum</u> <u>Beispiel</u> <u>,</u> <u>dass</u> <u>die</u> <u>meisten</u> <u>Säugetiere</u>											
NOUN	ADP	PUNCT	ADV	VERB	ADP	NOUN	PUNCT	SCONJ	DET	ADJ	NOUN
<u>ihre</u> <u>Jungen</u> <u>lebend</u> <u>gebären</u> <u>.</u>											
DET	NOUN	ADJ	VERB	PUNCT							

5.3.2 Konnektoren

Unter Konnektoren sind Worte oder Ausdrücke zu verstehen, die Sätze oder Satzteile miteinander verknüpfen (Breindl et al., 2014). Konnektoren können dabei unterschiedlicher Art sein und bspw. temporale („Sobald ich nach Hause komme, esse ich etwas.“) oder kausale Verknüpfungen („Ich esse einen Apfel, weil ich hungrig bin.“) ausdrücken. Konnektoren werden in LATIC mithilfe eines Algorithmus erkannt und ausgezählt. Zweiteilige Konnektoren (z. B. „Ich werde Sie *entweder* anrufen *oder* Ihnen eine Mail schicken.“) werden als ein Konnektor gezählt.

5.3.3 Lesbarkeitsindices

Lesbarkeitsindices sind Maße mit deren Hilfe die Lesbarkeit von Texten und Items eingeschätzt wird. In LATIC ist die Berechnung von vier verschiedenen Lesbarkeitsindices in der deutschen Sprache möglich.

5.3.3.1 Flesch. Die Formel des Fleschindices (Flesch, 1948) wurde von Amstad (1978) in die deutsche Sprache übertragen. Die Formel für die deutsche Sprache lautet:

$$\text{Flesch} = 180 - (\text{durchschnittliche Satzlänge}) \\ - (58,5 \times (\text{durchschnittliche Silbenanzahl pro Wort}))$$

Die Werte des Fleschindices reichen von 0 bis 100. Tabelle 5 zeigt, wie die Werte zu interpretieren sind (nach Amstad, 1978).

Tabelle 5

Interpretation der Flesch Werte

Schwierigkeit	Flesch Werte	Verständlich für
Sehr schwer	bis 29	Akademiker:innen
Schwer	30 – 49	
Mittelschwer	50 – 59	
Mittel	60 – 69	Schüler:innen im Alter von 13 bis 15 Jahren
Mittelleicht	70 – 79	
Leicht	80 – 89	
Sehr leicht	90 – 100	Schüler:innen im Alter von 11 Jahren

5.3.3.2 gSMOG. Der gSMOG (German Simple Measure of Gobbledygook) wurde ursprünglich von Bamberger und Vanecek (1984) entwickelt. Um gesamte Texte oder Items – statt nur einen Ausschnitt eines Textes bzw. Items – zu analysieren, passten Wild und Pissarek (2018) die Formel des gSMOG an:

$$gSMOG = \sqrt{\frac{(\text{Wörter} \geq 3 \text{ Silben}) \times 30}{\text{Satzanzahl}}} - 2$$

Die Werte reichen von vier bis 15 und geben das Lesealter in Klassenstufen an (Wild & Pissarek, 2018). Beachten Sie, dass bei der verbalen Ausgabe, die Werte gerundet werden. Bei einem Wert von 8,4 wird also bspw. ausgegeben, dass dieser Text bzw. das Item für eine 8. Klasse geeignet ist. Bei einem Wert von 8,5 wird ausgegeben, dass dieser Text bzw. das Item für eine 9. Klasse geeignet ist.

5.3.3.3 LIX. Der Lesbarkeitsindex, abgekürzt LIX, wurde ursprünglich von Carl-Hugo Björnsson (1968) entwickelt. Die Formel für die Berechnung des LIX lautet:

$$LIX = \frac{\text{Wortanzahl}}{\text{Satzanzahl}} + \frac{\text{lange Wörter}}{\text{Wortanzahl}} * 100$$

Der LIX kann Werte zwischen 0 und 100 annehmen. Anhand der Werte kann eine Einschätzung zur Schwierigkeit eines Textes bzw. Items vorgenommen werden (siehe Tabelle 6; zitiert nach Lenhard, W. & Lenhard, A., 2014–2017).

Tabelle 6*Interpretation der LIX Werte*

Schwierigkeit	LIX Werte	Ähnlichkeit mit
Sehr leicht	bis 29	
Leicht	30–39	Kinder- und Jugendliteratur
Mittel	40–49	Belletristik
Schwierig	50–59	Sachliteratur
Sehr schwierig	über 60	Fachliteratur

5.3.3.4 Vierte Wiener Sachtextformel. Insgesamt gibt es vier Wiener Sachtextformeln (WSTF) (Bamberger & Vancenek, 1984), die der Einschätzung der Schwierigkeit von Sachtexten dienen. Die vierte WSTF (Bamberger, 2006) ist von allen vier Formeln die genaueste und wurde daher in LATIC implementiert (Kefer, 2013). Die Formel (zitiert nach Wild & Pissarek, 2018) lautet:

$$\text{WSTF} = 0,2656 \times (\text{durchschnittliche Satzlänge}) + 0,2744 \times (\text{Anteil der Wörter} \geq 3 \text{ Silben in } \%) - 1,693$$

Die Werte reichen von vier bis 15 und legen nahe, für welche Klassenstufe die vorliegenden Texte bzw. Items geeignet sind. Dabei sind Texte bzw. Items mit einem Wert von über zwölf als schwierig anzusehen und mit Fachliteratur vergleichbar. Beachten Sie, dass bei der verbalen Ausgabe, die Werte gerundet werden. Bei einem Wert von 8,4 wird also bspw. ausgegeben, dass dieser Text bzw. das Item für eine 8. Klasse geeignet ist. Bei einem Wert von 8,5 wird ausgegeben, dass dieser Text bzw. das Item für eine 9. Klasse geeignet ist.

5.3.4 Lexikvarianz

Die Lexikvarianz, auch Type-Token-Relation genannt, stellt die Anzahl verschiedener Wörter dividiert durch die Wortanzahl dar (Johansson, 2009). Tabelle 7 beinhaltet Beispiele zur Veranschaulichung.

Tabelle 7*Beispiele zur Analyse der Lexikvarianz*

Beispiele	Lexikvarianz
<i>Eine Firma wurde beauftragt einen Swimmingpool zu bauen. Normalerweise brauchen drei Mitarbeiter dafür drei Tage. Wie viele Tage würde ein Mitarbeiter brauchen, wenn er den Swimmingpool alleine bauen müsste?</i>	Anzahl verschiedener Wörter: 23 Gesamte Wortanzahl: 29 Lexikvarianz: 0,79

Beispiele	Lexikvarianz
<i>Fischer Fritz fischt frische Fische.</i> Frische Fische fischt Fischer Fritz.	Anzahl verschiedener Wörter: 5 Gesamte Wortanzahl: 10 Lexikvarianz: 0,5

Anmerkung. Die Wörter, die zur Anzahl der verschiedenen Wörter gezählt werden, sind kursiv gedruckt.

5.3.5 Root Type-Token Ratio

Die Root Type-Token Ratio, auch Guirauds R genannt (Guiraud, 1960) ist angelehnt an die Lexikvarianz. Sie wird berechnet durch die Anzahl verschiedener Wörter dividiert durch die Wurzel der gesamten Wortanzahl. Je höher der Wert ist, desto höher ist die Anzahl an verschiedenen Wörtern (gemessen an der Wortanzahl insgesamt).

5.3.6 Silbenanzahl

Die Funktion der Silbenanzahl gibt die Anzahl der Silben des gesamten Textes bzw. Items aus.

5.3.7 Wortanzahl

Zeichenketten, die durch Leer- und/oder Satzzeichen voneinander getrennt werden, werden als Wörter erkannt. Symbole und Zahlwörter werden ebenfalls als Wörter erkannt.

5.3.8 Worthäufigkeitsklasse

Der Wert gibt einen Hinweis darauf, wie häufig die Worte, die im Text oder im Item vorkommen, in der deutschen Sprache vorkommen. Die Wörter werden dafür mit einem Corpus mit rund eine Million Einträgen abgeglichen, der von der Leipzig Corpora Collection (Goldhahn et al., 2012) zur Verfügung gestellt wurde. Angelehnt an die Leipzig Corpora Collection wird in LATIC die durchschnittliche Häufigkeitsklasse der einzelnen Wörter berechnet. Diese ergibt sich aus dem Logarithmus zur Basis zwei des Quotienten der Häufigkeit des häufigsten Wortes durch die Häufigkeitsklasse des betrachteten Wortes. Das bedeutet, dass das häufigste Wort im Corpus eine Häufigkeitsklasse von 0 hat. Wörter mit der Häufigkeitsklasse 1 kommen ungefähr halb so häufig vor wie das Wort aus Häufigkeitsklasse 0 usw.. Extrem seltene Wörter haben laut Leipzig Corpora Collection Häufigkeitsklassen von größer 20.

5.3.9 Zeichenanzahl mit und ohne Leerzeichen

Die Anzahl aller Zeichen inkl. oder ohne Leerzeichen wird ausgegeben.

6 Evaluation

Zur Evaluation von LATIC wurden unterschiedliche Funktionen separat getestet und optimiert (siehe auch Cruz Neri et al., 2022).

6.1 Evaluation des Annotierens

Die Evaluation des Annotierens in LATIC wurde vorgenommen als das Stanford CoreNLP in Version 4.2.0 (Manning et al., 2014) verfügbar war. Dafür wurde der TIGER Corpus 2.2 verwendet (Brants et al., 2004). Der TIGER Corpus besteht aus etwa 50.000 Sätzen bzw. 900.000 Tokens, die aus der deutschen Zeitung „Frankfurter Rundschau“ entnommen wurden. Die Tokens wurden semi-automatisch annotiert (Brants & Plaehn, 2000). Dabei wurde auf das TIGER Treebank Tagset (Smith, 2003) als auch das Penn Treebank Tagset (Santorini, 1990) zurückgegriffen.

Zunächst wurden zur Evaluation 10.002 Tokens des TIGER Corpus 2.2 (Brants et al., 2004) übernommen. Da bereits während des Testens deutlich wurde, dass die korrekte Rechtschreibung ausschlaggebend für eine korrekte Annotation ist, wurden fünf Tokens entfernt (z. B. Wörter, die ausschließlich in Großbuchstaben verfasst wurden). Final wurden entsprechend $N = 9.997$ Tags miteinander verglichen.

Im nächsten Schritt wurden die Tagsets überarbeitet, um die einzelnen Tokens vergleichen zu können. Dafür mussten die Tagsets des TIGER Corpus 2.2 (Brants et al., 2004) sowie des Stanford CoreNLP (Manning et al., 2014) ineinander überführt werden. Das Stanford CoreNLP (ebd.) annotiert in der deutschen Sprache bspw. Hilfsverben mithilfe des Tags AUX. Innerhalb des TIGER Corpus 2.2 (Brants et al., 2004) werden Hilfsverben jedoch anhand von mehreren Tags deutlich differenzierter annotiert. Nach dieser Überführung der Tagsets stimmten die Annotationen des TIGER Corpus 2.2 (ebd.) und die Annotationen des Stanford CoreNLP 4.2.0 (Manning et al., 2014) in 90,96 % Fällen überein ($n = 9.093$).

An dieser Stelle sei anzumerken, dass der Abgleich der Annotationen korrigiert werden musste. Erstens waren einige Tags, die im TIGER Corpus 2.2 (Brants et al., 2004) verwendet wurden, nicht in das Tagset des Stanford CoreNLP (Manning et al., 2014) überführbar. Dazu gehörten unter anderem die Tags TRUNC (abgetrenntes Kompositionserstglieder) und KOKOM (Vergleichskonjunktionen). Diese wurden daher aus dem Abgleich gestrichen. Zweitens wurden einige Tags in den Tagsets unterschiedlich definiert. Dazu gehörten u. a. Partikel sowie Eigennamen. Während verbale Partikel im TIGER Corpus 2.2 (Brants et al., 2004) als solche annotiert werden, werden diese anhand des Stanford CoreNLP (Manning et al., 2014) bewusst als Adpositionen oder Adverbien annotiert (siehe Abschnitt 5.1.10). Drittens wird im Stanford CoreNLP (Manning et al., 2014) jede

Zeichenkette separat annotiert. So erhält das Wort „Informatik-Dienstleistungsunternehmen“ bspw. die Tags Nomen – Satzzeichen – Nomen, während es im TIGER Corpus 2.2 (Brants et al., 2004) als Nomen annotiert wurde. Nach dieser sehr konservativen Korrektur waren 93,85 % der Annotationen des Stanford CoreNLP 4.2.0 (Manning et al., 2014) korrekt ($n = 9.271$).

Anhand der ersten 5.000 Annotationen wurden die häufigsten Fehlerquellen untersucht, die dem Stanford CoreNLP 4.2.0 (Manning et al., 2014) unterlaufen. Die meisten Fehler beim Annotieren wurden bei der Unterscheidung von Determinanten und Pronomen gemacht (ca. 21,74 % aller Fehler). Dies war jedoch zu erwarten, da die Unterscheidung zwischen Pronomen und Determinanten nicht immer eindeutig ist (Universal Dependencies Project, 2014–2020). Die zweithäufigste Fehlerquelle war die Unterscheidung zwischen Nomen und Eigennamen (ca. 13,71 % aller Fehler). Die dritthäufigste Fehlerquelle war die Unterscheidung von Adjektiven und Adverbien (ca. 9,36 % aller Fehler).

Die Korrektheit der Annotationen variiert innerhalb und zwischen verschiedenen Tagger-Softwares. Diese Varianz kommt dabei u. a. durch die verschiedenen Corpora und Textgenres zustande, die zur Evaluation der Annotationen verwendet werden. Eine Korrektheit der Annotationen wird bspw. bei nur 81,16 % bei spontansprachlichen Daten erreicht (z. B. Westpfahl & Schmidt, 2013), während der prozentuale Anteil korrekter Annotationen bei Zeitungsartikeln und erklärenden Texten mit bis zu 98,25 % deutlich höher liegt (Giesbrecht & Evert, 2009). In Anlehnung an vorheriger Forschung erzielen die Annotationen durch das in LATIC implementierte Stanford CoreNLP (Manning et al., 2014) gute Ergebnisse.

6.2 Evaluation der Silbenausählung

Die Silbenzählung erfolgt in der deutschen Sprache mithilfe eines eigenständig erstellten Algorithmus. Dieser Algorithmus wurde anhand von $N = 9.524$ Wörtern getestet, die laut der Leipzig Corpora Collection (Goldhahn et al., 2012) zu den frequentesten Wörtern in der deutschen Sprache gehören. Dabei wurden die Silben bei $n = 9.190$ Wörtern (96,49 %) korrekt gezählt. In einem zweiten Schritt optimierten wir den Algorithmus, indem wir (1) zusätzliche Regeln zur korrekten Silbenzählung, (2) eine Liste von Wörtern, bei denen die Silben nicht korrekt gezählt wurden, und (3) Anglizismen und Gallizismen, die im Deutschen üblich sind, ergänzten. Nach Optimierung des Algorithmus erreicht LATIC eine korrekte Silbenzählung für $n = 9.522$ der Testwörter (99,98 %).

6.3 Evaluation der Ausählung von Konnektoren

Die Ausählung der Konnektoren erfolgt ebenfalls auf Basis eines selbsterstellten Algorithmus. Dieser Algorithmus wurde auf Basis von Literatur zu Konnektoren erstellt,

vorrangig angelehnt an das Werk von Breindl et al. (2014). Zur Evaluation des Algorithmus wurden drei verschiedene Texte (Gesamtlänge: 2.211 Wörter) verwendet. LATIC erkannte im ersten Evaluationsdurchlauf $n = 287$ von $N = 348$ Konnektoren (82,47 %), die in den drei Texten vorkommen. Nach einer Optimierung des Algorithmus erkennt LATIC nun $n = 324$ von $N = 348$ Konnektoren (93,10 %). Die verbleibenden Fehler gehen fast ausschließlich auf polyseme Wörter zurück, die abhängig vom Kontext (nicht) als Konnektoren fungieren. So fungiert das Wort „kaum“ bspw. in dem Satz „Ich kann dich *kaum* hören“ nicht als Konnektor, während es im Satz „*Kaum* hatte ich das Fenster geöffnet, hörte ich die Vögel zwitschern“ als Konnektor fungiert (siehe auch Breindl et al., 2014).

7 Literatur

- Amstad, T. (1978). *Wie verständlich sind unsere Zeitungen?* [Dissertation]. Universität Zürich.
- Bamberger, R. (2006). *Erfolgreiche Leseerziehung. Theorie und Praxis*. Domino.
- Bamberger, R., & Vanecek, E. (1984). *Lesen-Verstehen-Lernen-Schreiben. Die Schwierigkeitsstufen von Texten in deutscher Sprache*. Jugend und Volk.
- Björnsson, C.H. (1968). *Læsbarhed* [Lesbarkeit]. Gad.
- Brants, S., Dipper, S., Eisenberg, P., Hansen, S., König, E., Lezius, W., Rohrer, C., Smith, G., & Uszkoreit, H. (2004). TIGER: Linguistic interpretation of a German corpus. *Journal of Language and Computation*, 2(4), 597–620. <https://doi.org/10.1007/s11168-004-7431-3>
- Brants, T., & Plaehn, O. (2000). Interactive Corpus Annotation. In M. Gavrilidou, G. Carayannis, S. Markantonatou, S. Piperidis, & G. Steinhauer (Hrsg.), *Proceedings of the second international conference on language resources and evaluation (LREC-2000)*. European Language Resources Association.
- Breindl, E., Volodina, A., & Waßner, U.H. (2014). *Handbuch der deutschen Konnektoren 2*. De Gruyter.
- Chowdhury, G.G. (2005). Natural language processing. *Annual Review of Information Science and Technology*, 37(1), 51–89. <https://doi.org/10.1002/aris.1440370103>
- Cruz Neri, N., Guill, K., & Retelsdorf, J. (2021). Language in science performance: Do good readers perform better? *European Journal of Psychology of Education*, 36(1), 45–61. <https://doi.org/10.1007/s10212-019-00453-5>
- Cruz Neri, N., Klückmann, F., & Retelsdorf, J. (2022). LATIC – A linguistic analyzer for text and item characteristics. *PLoS ONE*, 17(11), e0277250. <https://doi.org/10.1371/journal.pone.0277250>
- Bibliographisches Institut (2020). *Duden Wörterbuch*. <https://www.duden.de/>
- Eisenberg, P. (2013). *Grundriss der deutschen Grammatik: Band 2: Der Satz* (4. Auflage). Springer.
- Engel, U. (1979). Syntaktische Strukturen. In H. Steger (Hrsg.), *Das Zertifikat Deutsch als Fremdsprache* (S. 67–119). Deutscher Volkshochschul-Verband e.V. Bonn.
- Flesch, R. (1948). A new readability yardstick. *Journal of Applied Psychology*, 32(3), 221–233. <https://doi.org/10.1037/h0057532>
- Giesbrecht, E., & Evert, S. (2009). Is part-of-speech tagging a solved task? An evaluation of POS taggers for the German web as corpus. In I. Alegria, I. Leturia & S. Sharoff

- (Hrsg.), *Proceedings of the 5th Web as Corpus Workshop (WAC5)*, San Sebastian, Spain. http://www.stefan-evert.de/PUB/GiesbrechtEvert2009_Tagging.pdf
- Goldhahn, D., Eckart, T., & Quasthoff, U. (2012). *Building large monolingual dictionaries at the Leipzig corpora collection: From 100 to 200 languages*. Proceedings of the 8th International Language Resources and Evaluation (LREC'12).
- Guiraud, P. (1960). *Problèmes et méthodes de la statistique linguistique* [Probleme und Methoden der Sprachstatistik]. Presses Universitaires de France.
- Haider, H. (1991). Die Struktur der Nominalphrase – Lexikalische und funktionale Strukturen. In L. Hoffmann (Hrsg.), *Deutsche Syntax. Ansichten und Aussichten* (S. 304 – 333). De Gruyter.
- Hentschel, E., & Weydt, H. (1990). *Handbuch der deutschen Grammatik*. De Gruyter.
- Heppt, B., Haag, N., Böhme, K., & Stanat, P. (2015). The role of academic-language features for reading comprehension of language-minority students and students from low-SES families. *Reading Research Quarterly*, 50(1), 61–82. <https://doi.org/10.1002/rrq.83>
- Johansson, V. (2009). Lexical diversity and lexical density in speech and writing: A developmental perspective. *Working Papers*, 53(2008), 61–79.
- Kefer, I. (2013). Die Lesbarkeit von Schulbüchern für den Betriebswirtschaftslehreunterricht. Befunde und forschungsmethodische Grundprobleme. *Zeitschrift für Berufs- und Wirtschaftspädagogik*, 109(1), 94–107.
- Kurvon, D., & Adler, S. (2008). Introduction. In D. Kurzon & S. Adler (Hrsg.), *Adpositions. Pragmatic, semantic and syntactic perspectives* (S. 1–12). John Benjamins B.V.
- Lenhard, W., & Lenhard, A. (2014–2017). *Berechnung des Lesbarkeitsindex LIX nach Björnson*. <http://www.psychometrica.de/lix.html>.
- Manning, C.D., Surdeani, M., Bauer, J., Finkel, J., Bethard, S.J., & McClosky, D. (2014, June 23–24). *The Stanford CoreNLP Natural Language Processing Toolkit*. Proceedings of 52nd Meeting of the Association for Computational Linguistics: System Demonstrations, Baltimore, Maryland, United States. <https://www.aclweb.org/anthology/P14-5010.pdf>
- Pafal, J. (2011). *Einführung in die Syntax. Grundlagen – Strukturen – Theorien*. Springer.
- Santorini, B. (1990). *Part-of-speech tagging guidelines for the Penn Treebank Project*. Department of Computer and Information Science, University of Pennsylvania. <https://catalog.ldc.upenn.edu/docs/LDC99T42/tagguid1.pdf>
- Schiller, A., Teufel, S., & Stöckert, C. (1999). *Guidelines für das Tagging deutscher Textcorpora mit STTS (Kleines und großes Tagset)*. Institut für maschinelle

- Sprachverarbeitung. <https://www.ims.uni-stuttgart.de/documents/ressourcen/lexika/tagsets/stts-1999.pdf>
- Shaftel, J., Belton-Kocher, E., Glasnapp, D., & Poggio, J. (2006). The impact of language characteristics in mathematics test items on the performance of English language learners and students with disabilities. *Educational Assessment*, 11(2), 105–126. https://doi.org/10.1207/s15326977ea1102_2
- Smith, G. (2003). *A brief introduction to the TIGER treebank, version 1*. Universität Stuttgart. https://www.ims.uni-stuttgart.de/documents/ressourcen/korpora/tiger-corpus/annotation/tiger_introduction.pdf
- Universal Dependencies (2014–2020). *Universal POS tags*. <https://universaldependencies.org/u/pos/>
- Westpfahl, S., & Schmidt, T. (2013). POS für(s) FOLK – Part of Speech Tagging des Forschungs- und Lehrkorpus Gesprochenes Deutsch. *Journal for Language Technology and Computational Linguistics*, 1, 139–156.
- White, S. (2012). Mining the text: 34 text features that can ease or obstruct text comprehension and use. *Literacy Research and Instruction*, 51(2), 143–164. <https://doi.org/10.1080/19388071.2011.553023>
- Wild, J., & Pissarek, M. (2018). *RATTE Regensburger Analysetool für Texte*. <https://www.uni-regensburg.de/sprache-literatur-kultur/germanistik-did/downloads/ratte/index.html>